

Laboratório 01

Valdinar Pires da Silva Junior - RA: 206396

Introdução

Um conjunto de dados no formato tidy beneficia o analista de dados por permitir a manipulação dos mesmos de uma maneira unificada. De modo similar, métodos estatísticos são habitualmente implementados para receber dados neste formato. Desta maneira, a importação e tratamento de dados visando o referido formato reduzirá a criação de bancos de dados temporários, evitando problemas difíceis de diagnosticar.

Os conjuntos de dados apresentados correspondem ao número de casos de tuberculose observados em alguns países, juntamente com seus tamanhos populacionais.

Objetivos Ao fim deste laboratório, você deverá ser capaz de:

1- Caracterizar um conjunto de dados no formato tidy; 2- Manipular bases de dados, para responder perguntas específicas, utilizando o arcabouço implementado via tidyverse, com uso de verbos do pacote dplyr e apresentação gráfica de resultados utilizando o pacote ggplot2; 3- Notar que responder tais perguntas com bases de dados que não estejam no formato tidy requer trabalho adicional;

Manipulação de Dados no Formato Tidy

1- Carregue o pacote tidyverse

```
Warning: package 'tidyverse' was built under R version 4.4.3
```

```
Warning: package 'ggplot2' was built under R version 4.4.3
```

```
Warning: package 'tibble' was built under R version 4.4.3
```

```
Warning: package 'tidyr' was built under R version 4.4.3
```

```
Warning: package 'readr' was built under R version 4.4.3
```

```
Warning: package 'purrr' was built under R version 4.4.3
```

```
Warning: package 'dplyr' was built under R version 4.4.3
```

```
Warning: package 'stringr' was built under R version 4.4.3
```

```
Warning: package 'forcats' was built under R version 4.4.3
```

```
Warning: package 'lubridate' was built under R version 4.4.3
```

2- Apresente os bancos de dados table1, table2, table3, table4a e table4b, distribuídos juntamente com o pacote tidyverse. Para cada banco de dados, descreva textualmente se ele está no formato tidy e justifique cada uma de suas respostas.

```
#library(dplyr)
```

```
# table 1  
print(table1)
```

```
# A tibble: 6 × 4  
  country    year cases population  
  <chr>    <dbl> <dbl>      <dbl>  
1 Afghanistan 1999    745   19987071  
2 Afghanistan 2000   2666  20595360  
3 Brazil      1999  37737  172006362  
4 Brazil      2000  80488  174504898  
5 China       1999 212258 1272915272  
6 China       2000 213766 1280428583
```

Para que uma tabela seja classificada no aspecto do formato *Tidy*, alguns critérios devem ser atendidos. Sendo eles: cada coluna representa uma variável; cada linha representa uma observação e cada célula contém apenas único um valor. E ao analisar a **table1** concluímos que ela cumpre os requisitos e está no formato correspondente.

```
# table 1  
print(table2)
```

```
# A tibble: 12 × 4  
  country    year type      count  
  <chr>    <dbl> <chr>    <dbl>  
1 Afghanistan 1999 cases      745
```

2	Afghanistan	1999 population	19987071
3	Afghanistan	2000 cases	2666
4	Afghanistan	2000 population	20595360
5	Brazil	1999 cases	37737
6	Brazil	1999 population	172006362
7	Brazil	2000 cases	80488
8	Brazil	2000 population	174504898
9	China	1999 cases	212258
10	China	1999 population	1272915272
11	China	2000 cases	213766
12	China	2000 population	1280428583

A **table2** não está no formato *Tidy* pois a coluna *type* contém os valores “cases” e “population”, que representam duas variáveis distintas. Dessa forma, os valores que deveriam estar em colunas separadas estão concentrados em uma única coluna, não atendendo aos critérios do formato *Tidy*.

```
# table 1
print(table3)
```

```
# A tibble: 6 × 3
  country      year rate
  <chr>      <dbl> <chr>
1 Afghanistan 1999 745/19987071
2 Afghanistan 2000 2666/20595360
3 Brazil      1999 37737/172006362
4 Brazil      2000 80488/174504898
5 China       1999 212258/1272915272
6 China       2000 213766/1280428583
```

A **table3** não está no formato *Tidy* pois a coluna *rate* contém duas informações por célula, os “casos de tuberculose” e a “quantidade da população”.

```
# table 1
print(table4a)
```

```
# A tibble: 3 × 3
  country `1999` `2000`
  <chr>    <dbl> <dbl>
1 Afghanistan 745 2666
2 Brazil    37737 80488
3 China    212258 213766
```

A **table4a** não está no formato *Tidy*, pois os anos 1999 e 2000 estão representados como nomes de colunas. Dessa forma, o ano, que é uma variável, está distribuído em duas colunas diferentes, em vez de estar em uma única coluna. Por isso, a tabela está no formato wide, e não long, não cumprindo um dos critérios do formato Tidy.

```
# table 1
print(table4b)
```

```
# A tibble: 3 × 3
  country    `1999`    `2000`
  <chr>      <dbl>      <dbl>
1 Afghanistan 19987071  20595360
2 Brazil      172006362 174504898
3 China       1272915272 1280428583
```

A **table4b** não está no formato *Tidy* pois assim como a **table4a**, os anos 1999 e 2000 estão representados como nomes de colunas.

3- Utilizando comandos do pacote dplyr, determine a taxa de ocorrência de tuberculose para cada 10.000 pessoas. Armazene o resultado em um objeto chamado *taxas*.

```
library(dplyr)
#Calculando taxas na table1 para a cada 10.000 pessoas

table1 <- table1 %>% mutate(taxas = cases/population * 10000)
```

4- Apresente, utilizando comandos do pacote dplyr, o número de casos de tuberculose por ano.

```
# Casos de Tuberculose por ano

table1 %>% count(year, wt=cases)
```

```
# A tibble: 2 × 2
  year      n
  <dbl> <dbl>
1  1999 250740
2  2000 296920
```

5 - Apresente, utilizando comandos do pacote dplyr, o número de casos de tuberculose identificados em cada país.

```
#Forma mais compacta e simples
table1 %>% count(country, wt=cases)
```

```
# A tibble: 3 × 2
  country      n
  <chr>      <dbl>
1 Afghanistan 3411
2 Brazil      118225
3 China       426024
```

6 - Utilizando comandos do pacote dplyr, apresente uma tabela que descreva a mudança no número de casos, em cada país, ao longo dos anos de 1999 e 2000.


Diferença do número de casos de tuberculose do ano de 2000 em relação ao ano 1999

```
#
table1 %>% group_by(country) %>% summarise (diferenca = cases[2]-cases[1])
```

```
# A tibble: 3 × 2
  country      diferenca
  <chr>      <dbl>
1 Afghanistan  1921
2 Brazil      42751
3 China       1508
```

7 - Apresente um gráfico de linhas, preparado via ggplot2, apresentando a mudança na taxa de casos (por 10.000 habitantes) estratificado por país.

```
ggplot(table1, aes( x = year, y= taxas, colour=country)) +
  geom_line()
```



8 - Calcule a taxa para as tabelas table2 e table4a+table4b. Para isso, você precisará executar 4 passos:

Extrair o número de casos de tuberculose por país, por ano;

```
#Table2

# 1. Extrair o número de casos e o tamanho da população
table2_taxas <- table2 %>%
  pivot_wider(
    names_from = type,
    values_from = count
  )

# 2. Calcular a taxa para cada 10.000 pessoas
table2_taxas <- table2_taxas %>%
  mutate(taxas = (cases / population) * 10000)
```

```
# Calculando Table4

afCasos1999 <- table4a %>% filter(country == "Afghanistan") %>% select(`1999`)
afCasos2000 <- table4a %>% filter(country == "Afghanistan") %>% select(`2000`)

braCasos1999 <- table4a %>% filter(country == "Brazil") %>% select(`1999`)
braCasos2000 <- table4a %>% filter(country == "Brazil") %>% select(`2000`)
```

```
chiCasos1999 <- table4a %>% filter(country == "China") %>% select(`1999`)
chiCasos2000 <- table4a %>% filter(country == "China") %>% select(`2000`)
```

Extrair o tamanho da população correspondente, por ano;

```
afPop1999 <- table4b %>% filter(country == "Afghanistan") %>% select(`1999`)
afPop2000 <- table4b %>% filter(country == "Afghanistan") %>% select(`2000`)

braPop1999 <- table4b %>% filter(country == "Brazil") %>% select(`1999`)
braPop2000 <- table4b %>% filter(country == "Brazil") %>% select(`2000`)

chiPop1999 <- table4b %>% filter(country == "China") %>% select(`1999`)
chiPop2000 <- table4b %>% filter(country == "China") %>% select(`2000`)
```

Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000 e Armazenar o resultado numa variável apropriada;


```
afTaxas99 <- (afCasos1999$`1999`/afPop1999$`1999`)*10000
afTaxas00 <- (afCasos2000$`2000`/afPop2000$`2000`)*10000

braTaxas99 <- (braCasos1999$`1999`/braPop1999$`1999`)*10000
braTaxas00 <- (braCasos2000$`2000`/braPop2000$`2000`)*10000

chiTaxas99 <- (chiCasos1999$`1999`/chiPop1999$`1999`)*10000
chiTaxas00 <- (chiCasos2000$`2000`/chiPop2000$`2000`)*10000
```

9 - Refaça o gráfico da questão 7 para os dados apresentados em table2.

```
ggplot(table2_taxas, aes(x = year, y = taxas, colour = country)) +
  geom_line()
```



10 - Utilizando o comando `pivot_longer`, transforme `table4a` em um objeto no formato tidy. Armazene o resultado num objeto chamado `tidy4a`.

```
#Deixando a coluna pais quieto, transforme os anos em uma coluna com o nome
"ano", e pegue o valores e transforme em uma coluna com o nome "casos".

tidy4a <- table4a %>% pivot_longer(-country, names_to = "ano", values_to =
"casos")
```

11 - Refaça o item 10 para o objeto `table4b`. Armazene o resultado num objeto chamado `tidy4b`.

```
#Deixando a coluna pais quieto, transforme os anos em uma coluna com o nome
"ano", e pegue o valores e transforme em uma coluna com o nome "população".

tidy4b <- table4b %>% pivot_longer(-country, names_to = "ano", values_to =
"população")
```

12 - Combine os objetos `tidy4a` e `tidy4b` em um único objeto, utilizando o comando `left_join`. Apresente uma explicação textual sobre o que faz o referido comando.

```
tidy4 <- tidy4a %>%
  left_join(tidy4b, by = c("country", "ano"))
```

O `left_join()` usa as colunas indicadas (`country` e `ano`) para encontrar as linhas correspondentes nas duas tabelas e acrescentar as informações da tabela da direita à tabela da esquerda.

13 - Use o comando `pivot_wider` para transformar o objeto `table2` em um objeto com formato tidy.


```
#Transformando linhas em colunas

#Names - Onde esta os nomes/variaveis para virar colunas
#Contagens - Onde estão os valores numericos para ficar corretamente distribuidos
na tabela

table2 %>% pivot_wider(names_from = 'type', values_from = 'count')
```

```
# A tibble: 6 × 4
  country    year cases population
  <chr>      <dbl> <dbl>      <dbl>
1 Afghanistan 1999    745  19987071
2 Afghanistan 2000   2666  20595360
3 Brazil      1999  37737  172006362
4 Brazil      2000  80488  174504898
5 China       1999 212258 1272915272
6 China       2000 213766 1280428583
```

14 - Observe que a coluna rate do objeto table3 é um texto mostrando a fração que formaria a taxa de casos de tuberculose. Transforme o objeto table3 em um objeto com formato tidy separando a coluna 3 em duas outras colunas: cases e population, utilizando o comando separate. Utilize o argumento convert para transformar o resultado em um objeto numérico.

```
table3 %>%
  separate(
    rate,
    into = c("cases", "population"),
    sep = "/",
    convert = TRUE
  )
```

```
# A tibble: 6 × 4
  country    year cases population
  <chr>      <dbl> <int>      <int>
1 Afghanistan 1999    745  19987071
2 Afghanistan 2000   2666  20595360
3 Brazil      1999  37737  172006362
4 Brazil      2000  80488  174504898
5 China       1999 212258 1272915272
6 China       2000 213766 1280428583
```